

Laboratorio: Limpieza de Datos para Minería de Datos

Complete los campos y reemplace los textos entre corchetes con los resultados obtenidos al ejecutar su script.

Integrantes:

- PARI MAMANI MICHELLE JHOVANA
- MAMANI POMA RAMIRO
- MALDONADO GONZALES PABLO SANTOS

Objetivo

Aplicar un proceso de limpieza de datos para detectar y corregir registros duplicados, valores faltantes, formatos inconsistentes y valores atípicos antes de realizar análisis o minería de datos.


¿Cómo lo hacemos?

Paso 1: Preparar el entorno

1.1. Instalar las librerías necesarias

Abre tu terminal (PowerShell, CMD o Bash) y ejecuta:


`pip install pandas numpy`



```
PS C:\xampp\htdocs\Practica> pip install pandas numpy
Requirement already satisfied: pandas in c:\users\usuario\appdata\local\programs\python\python311\lib\site-packages (3.0.6)
Requirement already satisfied: numpy in c:\users\usuario\appdata\local\programs\python\python311\lib\site-packages (2.4.6)
Requirement already satisfied: python-dateutil>=2.8.2 in c:\users\usuario\appdata\local\programs\python\python311\lib\site-packages (from pandas) (2.9.0.post0)
Requirement already satisfied: tzdata in c:\users\usuario\appdata\local\programs\python\python311\lib\site-packages (from pandas) (2026.5)
Requirement already satisfied: six>=1.5 in c:\users\usuario\appdata\local\programs\python\python3
```

1.2. Verificar instalación

`python -c "import pandas; import numpy; print('¡Listo!')"`



```
Requirement already satisfied: tzdata in c:\users\usuario\appdata\local\programs\python\python311\lib\site-packages (from pandas) (2026.5)
Requirement already satisfied: six>=1.5 in c:\users\usuario\appdata\local\programs\python\python311\lib\site-packages (from python-dateutil>=2.8.2->pandas) (1.17.0)

[notice] A new release of pip available: 22.3 -> 26.2.1
[notice] To update, run: python.exe -m pip install --upgrade pip
PS C:\xampp\htdocs\Practica> python -c "import pandas; import numpy; print('¡Listo!')"
¡Listo!
PS C:\xampp\htdocs\Practica>
```

Paso 2: Cargar el dataset

Crea un archivo llamado **practica.py** y escribe:

```
import pandas as pd
import numpy as np
```

Cargar el dataset

```
df = pd.read_csv("dataset_con_errores.csv")
```

Ver dimensiones


```
print("Filas:", df.shape[0])
print("Columnas:", df.shape[1])
```

Ver primeras filas

```
print("\nPrimeras 5 filas:")
print(df.head())
```

Ejecuta el archivo:

`python practica.py`



```
PS C:\xampp\htdocs\Practica> python practica.py
Filas: 210
Columnas: 10

Primeras 5 filas:
   id  nombre  edad  ...  email  telefono  categoria
0   1   carlos  56.0  ...  carlos@gmail.com  +52 194 648 4120  D
1   2     Ana  69.0  ...  ana@yahoo.com  +521409942192  C
2   3   Laura  46.0  ...  laura2@hotmail.com  +526723228854  A
3   4   José  32.0  ...  josé3@hotmail.com  NaN  D
```

Paso 3: Explorar y detectar problemas

```
# -----
# DIAGNÓSTICO DEL DATASET
# -----
```

```
print("\n=== INFORMACIÓN GENERAL ===")
print(df.info())

print("\n=== VALORES NULOS ===")
print(df.isnull().sum())

print("\n=== FILAS DUPLICADAS ===")
print("Cantidad:", df.duplicated().sum())

print("\n=== ESTADÍSTICAS DE EDAD ===")
print(df["edad"].describe())

print("\n=== VALORES ÚNICOS DE GÉNERO ===")
print(df["genero"].value_counts(dropna=False))

print("\n=== VALORES ÚNICOS DE PAÍS ===")
print(df["pais"].value_counts(dropna=False))
```

Actividad - Pausa (Análisis):

- ¿Cuántos valores faltantes hay?

Hay 83 valores faltantes en total, distribuidos entre las columnas edad, género, ingresos, fecha de nacimiento, email y teléfono.

- ¿Hay edades extrañas (negativas, mayores a 100)?

Sí. Se encontraron edades extrañas. La edad mínima es 0 y la máxima es 999, por lo que existen valores inválidos.

- ¿Los géneros están escritos de forma consistente?

No. Los géneros tienen diferentes formatos, como M, m, F, f, Masculino, MASCULINO, Femenino y FEMENINO.

- ¿Los países tienen diferentes formatos?

Sí. Los países presentan diferencias de mayúsculas, minúsculas, espacios y acentos, por ejemplo mexico, México, MÉXICO y Mexico.